

世界モデルによるクリフディメンション攻略

d-hacks B3 omote^{1,a)}

概要

クリフディメンションの背面飛び移りを、3 cm 突起の有限な把持容量を含む力学課題として定式化し、前腕干渉を含む平面 5 リンク人体の多相軌道最適化から離手位相・装置周期・体重ごとの必要把持容量を求めた。実行可能な離手位相は往路の狭い窓に限られ、必要容量は捕捉後の保持で決まる。さらに、最適化の KKT 双対変数（価値・costate・影の価格）を学習対象とする双対場学習を提案し、同一物理のコンパイル環境で行動模倣・強化学習・オラクル MPC と閉ループ比較した。執行系の離散化と活性制約上の最適解が閉ループの成否を支配することを示す。

1. はじめに

クリフディメンションは、上下に動く突起（クリフ A）に両手でぶら下がった状態から体を振って離手し、空中で向きを変え、左右に動く突起（クリフ B）を両手で捕捉する課題である。突起の奥行きは 3 cm であり、成否は重心の放物線だけでなく、手先の相対速度・掛かり代・指の把持容量に依存する。本研究の最終目標は、身長・体重・筋力の異なる誰にとっても「どう飛べば届くか」を計算し、それを学習器が自律的に獲得できるようにすることである。3 cm 突起の捕捉は報酬が極端に疎で、成功軌道が一度も観測されないまま学習が停滞する（第 8 節で実測する）。そこで本稿は二段構えを採る。第一段（第 4–6 節）は、学習に先立ち「物理的に何が要求されるか」を決定論的に確定させる。第二段（第 7–8 節）は、その最適化が副産物として与える**双対変数**を学習の教師と表現にする新しい原理を提案し、小規模実験で検証する。貢献は、(i) 前腕干渉を含む修正モデルによる離手位相の実行可能窓と必要把持容量の T - m -体格マップ、その乗数による支配制約の同定と能力弾性、(ii) 双対場学習の定式化（オラクルの双対ラベル、Sobolev 学習、Pontryagin 制御と短地平線 MPC、包絡線定理による転移）、(iii) 最適化器と同一物理の高速環境と、オラクル・行動模倣・強化学習の同一土俵での比較、および閉ループ失敗の執行系への分解（制御周期・標準化・活性制約上の最適解）、である。

2. 関連研究

ぶら下がり移動（brachiation）の力学と制御。 テナガザルの腕渡りは点質量振り子で近似でき、離手・捕捉時の衝突損失が移動コストを決める [1], [2]。Gomes と Ruina は 5 リンク平面猿モデルで、衝突を避ける「エネルギー零コスト」の腕渡り軌道が存在することを示した [3]。ロボット側では 2 リンク腕渡りロボットのふりこ励振と離手制御 [4], [5] が古典で、近年は連続的な把持・離手を含む全身軌道最適化と学習が試みられている。本課題は、これらと異なり (i) 両把持点が周期運動し、(ii) 把持容量が 3 cm 突起で有限、(iii) 背面（体を 180 度回して）捕捉する、という三つの制約が同時に効く点に特徴がある。**空中でのひねりと姿勢制御。** 角運動量保存下での空中ひねりは、落下猫 [7] 以来、体節の相対運動で全身の向きを変える幾何学的位相の問題として理解されている [8], [9]。本稿の 3 次元縮約モデルは体幹 6 自由度と左右独立の肩・肘・股・膝をもち、離手時の角運動量と空中の四肢運動でひねりを生成する。離手・捕捉の左右時間差を許す点で、両手同時の brachiation モデルと異なる。**接触を含む軌道最適化。** 多相の直接コロケーション [10], [11], [12] と接触陰的最適化 [13], [14] は、接触の生成・消滅を含む全身運動の生成に広く用いられる。本稿は相の順序が既知（振り→飛行→捕捉→保持）なので多相定式化を採り、Hermite-Simpson の暗黙力学、把持容量のエピグラフ変数、順応捕捉相と離手時刻誤差のロバスト・シナリオ、多スタートと連続法による下包絡線を組み合わせた。KKT 乗数を包絡線定理 [15], [16] で能力・身体パラメータの感度に翻訳する点が、通常の運動合成と異なる。**運動技能の学習と世界モデル。** モデルフリー強化学習 [17] や運動模倣 [18] は疎報酬の離散的成功課題で停滞しやすく、世界モデル [19], [20], [21], [22] は状態遷移を学んで想像上の経験を増やす。軌道最適化を教師とする方法には、最適制御解へ方策を回帰させる誘導方策探索 [23]、訪問状態を専門家がラベル付けする DAgger [24]、MPC の価値を学習する POLO [25] がある。これらはいずれも主変数（行動・状態遷移・価値）を回帰する。価値の勾配を学習信号に使う研究として、値勾配学習 [26]、Sobolev 学習 [27]、確率的値

¹ d-hacks

^{a)} kotaro3150@keio.jp




図 1 装置運動 ($T = 20$ s). 左: 先端間距離 x と高低差 h . 右: 装置速度 (平滑化と三角波).

勾配 [28] があり, Pontryagin の最小原理を学習に組み込む研究として Pontryagin 微分可能計画法 [29] や到達可能性の深層学習 [30] がある. 制約付き強化学習 [31], [32] はラグランジュ乗数を報酬の重みとしてオンラインで学習する. 本稿の双対場学習はこれらの延長にあるが, (i) 学習対象を「厳密オラクルの KKT 双対変数 (costate と制約価格) の場」と定め, (ii) 行動を方策学習なしに Hamiltonian の点ごとの最小化から導き, (iii) 包絡線定理により身体パラメータへの転移則を場の一部として得る, という三点を一体の原理として提示し, 同一環境上でオラクル・主変数模倣・強化学習と比較する点が新しい. **把持容量の生理.** 3cm 前後の縁でのぶら下がり是指屈筋群の等尺性最大筋力で決まり, 縁の奥行きと把持形態 (ハーフクリンプ/オープン) で最大指力が大きく変わる [33], [34]. 本稿は両手容量を 1300 N (体重比で約 2 BW) を基準に, 能力スケールと体格の関数として掃引した.

3. 問題設定

3.1 装置と座標系

$+x$ を A から B, $+y$ を鉛直上向きとし, B の把持面高さを $y = 0$ に置く. 装置周期を T (片道 $T/2$), $u = t \bmod T$, 位相 $\phi = u/T \in [0, 1)$ とし, 先端点を $\mathbf{p}_A(t) = (0, h(t))$, $\mathbf{p}_B(t) = (x(t), 0)$, $x = 1.80 + 0.90\rho_\epsilon(\phi)$, $h = 0.90(1 - \rho_\epsilon(\phi))$ [m] とする (図 1). ρ_ϵ は端点で速度が 0 になる平滑化三角波 (折り返し時間 $\epsilon = 0.20$ s) で, $\phi < 0.5$ が往路 (A 下降・B 遠ざかる), $\phi \geq 0.5$ が復路である.

3.2 突起形状と成功条件

突起は前面から 3cm 張り出し, 鉛直高さ 5cm, その下 15cm が本体前面 (手首・前腕の移動を制限する面), それより下は開放空間である. 先端上縁には手への食い込みを避ける R5mm の丸みを与えた. A を両手で把持し胸を A に向けた静止状態から開始し, 1 周期 T 以内に離手, B を両手で捕捉して 2.0s 保持できれば成功とする. 把持負荷は両手合計の突起反力 $\mathbf{R}$ に対し $U = \|\mathbf{R}\|/F_{\text{cap}}$, $U_{\text{peak}} = \max_t U$ で表す (F_{cap} : 両手の把持容量, 基準値 1300 N). 努力指標は

$$E_{\text{eff}} = \frac{1}{t_{\text{ref}}} \int \left\{ \frac{1}{n_j} \sum_j \left(\frac{\tau_j}{\tau_j^{\text{cap}}} \right)^2 + U^2 \right\} dt \quad (1)$$

とする ($t_{\text{ref}} = 1$ s).

4. 縮約モデルと軌道最適化

4.1 平面 5 リンク人体

前腕+手, 上腕, 体幹+頭部, 大腿, 下腿の 5 リンク (左右合算) を, de Leva [35] の質量比・重心位置・回転半径から体重 m と身長 H (基準 1.75 m, 全リンク長を $H/1.75$ でスケール) に合わせて構成した. 両手の掛かり線 (PIP) を基底座標 $\mathbf{p}_h$ とし, $\mathbf{q} = (\mathbf{p}_h, \theta_1, \dots, \theta_5)$ の運動方程式 $\mathbf{M}(\mathbf{q})\ddot{\mathbf{q}} + \mathbf{h}(\mathbf{q}, \dot{\mathbf{q}}) = \mathbf{B}\boldsymbol{\tau} + \mathbf{J}^\top \mathbf{R}$ を CasADi で記号導出した. 把持中は $\mathbf{p}_h$ が装置に従属し, $\mathbf{R}$ は拘束力として第 1, 2 行から得られる. 肘・肩・股・膝のトルク上限 (両側合計 120/160/300/240 N m), 関節可動域 (肩の過伸展 35 度まで), 関節角速度 10 rad/s, 指令トルク変化率 $10\tau^{\text{cap}}/\text{s}$ を課した. **前腕干渉:** 把持中の前腕は突起面に沿って垂れ下がるので, 掛かり線から 8cm と 16cm の前腕上の点の突起面より手前 (1cm, 2cm の余裕) に留まる制約を全相で課す. 初期実装にはこの制約がなく, 最適化器は前腕を突起板に食い込ませて振り上げる非物理解を返していた (3 次元モデルの構築中に発見). 本稿の結果はすべて修正モデル (v3) で再計算したものである.

4.2 相構成と捕捉モデル

待機 (静止把持) → 振り (A に拘束) → 飛行 (自由鎖, 内部トルクのみ) → 捕捉 → 保持 (B に拘束 2.0s) の多相問題とした. 捕捉は掛かり線が B 先端に一致し, 手先が把持面へ向かう ($v_{\text{rel}, y} \leq 0$, 壁から離れる速度 ≤ 0.5 m/s, $\|\mathbf{v}_{\text{rel}}\| \leq 4$ m/s) ときの完全非弾性衝突として扱い, 衝撃力積 $\mathbf{\Lambda}$ を $\mathbf{M}(\dot{\mathbf{q}}^+ - \dot{\mathbf{q}}^-) = \mathbf{J}^\top \mathbf{\Lambda}$ から求める. 捕捉負荷は, 力積を $\Delta_c = 50$ ms に均した力と捕捉直後の持続張力 $\mathbf{R}_H(0)$ の重ね合わせ

$$U_{\text{catch}} = \frac{\frac{\|\mathbf{\Lambda}\|}{\Delta_c} + \|\mathbf{R}_H(0)\|}{F_{\text{cap}}} \quad (2)$$

とした. 順応捕捉 (剛性 40 kN/m, 減衰 1.5 kN s/m の Hunt-Crossley 型フック) を最適化の内部に置く定式化も実装し, 剛体衝突との差を比較する. 突起反力には片側支持 $R_y \geq 0$ と摩擦・引っ掛かり錐 (壁から離れる向き $\mu_{\text{out}} = 1.0$, 壁へ向かう向き $\mu_{\text{in}} = 2.0$) を課し, 壁・突起との干渉は各部位の平滑化 max 制約で除いた.

4.3 目的関数と数値法

「必要把持容量の最小化」を主目的とし, $J = w_U U_{\text{peak}} + w_E E_{\text{eff}}$ ($w_U = 10, w_E = 1$) を最小化した. U_{peak} は epigraph 変数で, $U_{\text{peak}} \times 1300$ N がその離手位相で成功するために必要な両手容量である. 離散化は圧縮型 Hermite-Simpson (振り 150, 飛行 30, 保持 60 区間, 暗黙力学), 求解は IPOPT [36] (CasADi [37]) である. 非凸性への対

処として、各条件を複数の振り初期解（振幅・周期・立ち上がりの異なる 6 種）から解き、さらに位相方向に隣接解を暖機初期値とする連続法を往復させて下包絡線を取った。飛行中の重心放物線・角運動量保存を許容帯付き制約として追加し、全解を RK4 1 ms で再積分して一致を監査した。

4.4 双対変数と感度

関節トルク容量・摩擦係数・関節速度上限・捕捉速度上限を Opti のパラメータとして定式化し、解の乗数からラグランジアンのパラメータ勾配 $\partial J^*/\partial \ln p$ （包絡線定理）を得る。これは「その能力が 1% 増えたとき必要容量がどれだけ減るか」という影の価格である。同様に、制約種別（摩擦錐・可動域・関節速度・壁・捕捉幾何）ごとの乗数量と、容量エピグラフ制約の乗数の相別配分（振り・捕捉・保持）を記録する。後者は「 U_{peak} をどの瞬間が決めているか」を、 U が U_{peak} に達しているかどうかではなく乗数で判定する（ミニマックス解では等振動により複数箇所が同時に U_{peak} に触れるため、到達だけでは支配性を判定できない）。

5. 3 次元人体モデル

体幹 6 自由度と左右独立の肩 2・肘 1・股 1・膝 1 をもつ 14 自由度のひねりモデルを CasADi で構築し、左右の手の離手・捕捉の時間差と把持幅を持つ戦略ごとに同じ多相最適化を解く枠組みを実装した（片手ごとの把持負荷、Baumgarte 型の拘束安定化、2 段階求解）。両手を合算する平面モデルは衝撃が先に触れる手に集中する効果を過小評価するので、片手容量の要求は平面値より大きい。その掃引は計算中であり、本稿では枠組みと予備結果のみ報告する。MuJoCo [38] 上の 31 関節＋指開閉の人体環境と有限容量把持モデルも構築し、受入試験を自動化した。

6. 結果 I：物理

6.1 離手位相の実行可能窓

修正モデルの再計算は $T \in \{16, \dots, 24\} \text{ s} \times m \in \{60, \dots, 75\} \text{ kg} \times 16$ 位相の 864 条件について進行中で、本稿執筆時点で 98 条件（ $T = 16\text{--}19 \text{ s}$ ）が終わっている。その範囲で、離手位相 ϕ_ℓ の実行可能範囲は明確な窓をもつ（図 2, 表 1）。往路の $\phi_\ell \in [0.25, 0.31]$ では全身体で $U_{\text{peak}} = 1.03\text{--}1.49$ （両手 1300 N 基準；体重比では 2.3–2.7 BW）で解が得られる。 $\phi_\ell = 0.375$ では必要容量が 2.4–3.7（5–7 BW, 超人的）へ跳ね上がり、 $\phi_\ell \geq 0.44$ では片側からの振りでは先端間距離 2.5–2.7 m の水平射出速度が得られず（到達不足 3–15 cm）、実行不能である。復路の谷は、これまでに計算できた $m = 60 \text{ kg}$ （ $T = 17, 18 \text{ s}$ ）で $\phi_\ell \approx 0.69\text{--}0.81$ に往路と同等の容量で現れる（他の体重の復路は計算中）。旧モデル（前腕干渉なし）の「全位相で

表 1 実行可能窓の要約（位相について最小化した必要容量 [両手 1300 N 比 / BW]）。

T [s]	m [kg]	最良 ϕ_ℓ	U_{peak}	BW
16	60	0.250	1.03	2.27
16	63	0.250	1.08	2.28
16	66	0.250	1.14	2.29
16	69	0.250	1.20	2.30
16	72	0.250	1.28	2.35
16	75	0.250	1.40	2.47
17	60	0.250	1.03	2.28
17	63	0.250	1.08	2.27
17	66	0.250	1.14	2.30
17	69	0.250	1.20	2.31
17	72	0.250	1.26	2.32
17	75	0.250	1.37	2.41
18	60	0.250	1.03	2.28
18	63	0.250	1.08	2.28
18	66	0.250	1.14	2.29
18	69	0.250	1.20	2.31
18	72	0.250	1.26	2.32
18	75	0.250	1.36	2.41
19	60	0.250	1.03	2.27
19	63	0.250	1.09	2.28
19	66	0.250	1.14	2.30
19	69	0.250	1.20	2.31
19	72	0.250	1.26	2.32
19	75	0.250	1.40	2.47

2.3–2.9 BW の二谷構造」は、前腕を板に食い込ませた振りに依存した見かけの結果であり、修正モデルでは成立しない。

6.2 支配制約と能力弾性

容量エピグラフの乗数は保持相 85%・捕捉 14%・振り 2% に配分され、必要把持容量を決めているのは捕捉後に振れ戻る身体を支える保持である（振りの U は 0.5–0.8 にすぎない）。関節トルク容量の弾性 $\partial \ln J^*/\partial \ln \tau^{\text{cap}}$ は中央値 -0.27 で、筋力（トルク容量）が 10% 増えれば必要把持容量はおおよそ 3% 減る。引っ掛かり係数 μ_{out} の価格はその 1/10 以下、関節角速度上限と捕捉速度上限の価格は 0（拘束的でない）である。体重については、能力を絶対値で固定すると必要容量は体重比でも増え（60 kg で 2.3, 72 kg で 2.7 BW）、身長は長いほど有利である（第 8 節の身体掃引、計算中）。

6.3 モデル誤差と順位の保存

剛体衝突を順応捕捉に置き換えると、最適化の内部で手先の接近速度が下がり、必要容量の変化は小さい（ $T = 18 \text{ s}$, $m = 66 \text{ kg}$ で +2.3%）。一方、実行誤差に対する余裕は無い：最適解は可動域端・壁・錐の上を通るため、執行系の離散化（20 ms の零次保持）だけで振りが崩れ、2 ms の執行系でも捕捉幾何の余裕は先端から 2–3 cm である（第 8.4 節）。モデル変種（ $\mu_{\text{out}} \pm$, 関節能力 $\pm$, 身長）に対して最良位




図 2 離手位相 ϕ_ℓ と必要両手持持容量（修正モデル，98 条件計算済み；グリッドは計算継続中）． Δ は 2（両手 2600 N，超人的）を超える解， $\times$ は実行不能（到達不足），灰色は復路．

相の順位が保たれるかどうかの解析（Spearman/Kendall）は，修正モデルの再計算後に表として示す（計算中）．

7. 提案：双対場学習

7.1 動機：主変数ではなく双対変数を学ぶ

世界モデル [19], [20] は状態遷移 $s' = f(s, a)$ （主変数）を学習し，方策はその上で探索する．しかし本課題のように成否が硬い物理制約（把持容量・摩擦錐・可動域・壁）で決まる運動では，学習に必要なのは「次に何が起きるか」ではなく「ここから先，どの物理法則がどれだけ効いてくるか」である．軌道最適化の KKT 条件はまさにこの情報を与える．最適解の随伴状態（costate） $\mathbf{p} = \partial V^*/\partial \mathbf{x}$ は「状態を少し変えたとき到達可能な最良の結果がどれだけ変わるか」，各制約のラグランジュ乗数 λ_k は「その制約を少し緩めたとき結果がどれだけ改善するか（影の価格）」であり，包絡線定理により

$$\frac{\partial V^*}{\partial \boldsymbol{\theta}} = \frac{\partial \mathcal{L}}{\partial \boldsymbol{\theta}} = \frac{\partial \mathcal{L}}{\partial \boldsymbol{\theta}} + \sum_k \lambda_k \frac{\partial g_k}{\partial \boldsymbol{\theta}} \quad (3)$$

が身体・装置パラメータ $\boldsymbol{\theta}$ （体重，身長，筋力，摩擦係数，周期）に対しても成り立つ．本稿はこの**双対場**（value・costate・価格の場）を学習対象とすることを提案する（図 3）．主変数の学習（方策の模倣，状態遷移モデル）と異なり，双対場は (i) 密である（成功／失敗ではなく，全状態で微分可能なスカラーとベクトル），(ii) 行動に直接変換できる（Pontryagin の最小原理），(iii) パラメータへの転移則を自ら含む（式 (3) ），という 3 つの性質をもつ．

7.2 オラクルによる双対ラベル

第 4 節の多相軌道最適化を，任意の振り状態 $\mathbf{x}_0 = (\boldsymbol{\theta}, \dot{\boldsymbol{\theta}})$ ，時刻 t_0 ，身体 $\boldsymbol{\theta}_b$ から解く「残り最適化問題」に拡張した（待機相なし，離手時刻自由）．初期条件 $\mathbf{X}_0 - \mathbf{x}_0 = \mathbf{0}$ の乗数から costate $\mathbf{p}^*(\mathbf{x}_0, t_0) = \partial J^*/\partial \mathbf{x}_0$ を，時刻パラメータの乗数から $\partial J^*/\partial t_0$ を得る．一つの解は，価値 $V^* = J^*$ ，必要把持容量 U^* ，最適離手までの残り時間 τ^* ，costate $\mathbf{p}^*$ ，制

約種別ごとの乗数量 $\Lambda_k = \sum |\lambda|$ （摩擦錐・可動域・関節速度・壁・捕捉幾何），容量エピグラフの相別乗数（ $\sum = w_U$ ）を同時に与える．有限差分との比較では $\mathbf{p}^*$ は 0.4% で一致した．参照軌道に沿った状態（15 節点おき）と，可動域・壁の内側で摂動した状態（角度 $\sigma = 0.06\ell$ rad，角速度 0.4ℓ rad/s， $\ell \in \{1, 2\}$ ）から，402 個の残り最適化問題を 54 本の参照軌道（ $T \in \{16, \dots, 19\}$ s， $m \in \{60, \dots, 75\}$ kg）について解いた．

7.3 Sobolev 学習と Pontryagin 制御器

双対場ネットワーク $V_\theta(\mathbf{x}, \phi, \boldsymbol{\theta}_b) \rightarrow (V, U, \tau)$ を，値と勾配の両方を合わせる Sobolev 損失

$$\mathcal{L} = \|V_\theta - V^*\|^2 + \|U_\theta - U^*\|^2 + \|\tau_\theta - \tau^*\|^2 + \alpha \|\nabla_{\mathbf{x}} V_\theta - \mathbf{p}^*\|^2 \quad (4)$$

で学習する（各項は学習データの分散で正規化， $\alpha = 1$ ； $\alpha = 0$ が値のみの消去実験）．制御器は**方策ネットワークを学習しない**．剛体力学は既知（制御アフィン $\ddot{\boldsymbol{\theta}} = \mathbf{c}(\mathbf{x}, t) + \mathbf{D}(\mathbf{x}, t)\mathbf{u}$ ，手先反力 $\mathbf{R} = \mathbf{R}_0 + \mathbf{R}_u\mathbf{u}$ ）なので，各制御周期で Hamiltonian

$$H(\mathbf{u}) = \frac{w_E}{t_{\text{ref}}} \left(\frac{1}{4} \|\mathbf{u}\|^2 + \frac{\|\mathbf{R}(\mathbf{u})\|^2}{F_{\text{cap}}^2} \right) + \mathbf{p}_\theta(\mathbf{x}, t)^\top (\mathbf{c} + \mathbf{D}\mathbf{u}) \quad (5)$$

を，トルク上限，摩擦・引っ掛かり錐，容量 $\|\mathbf{R}(\mathbf{u})\| \leq U_\theta F_{\text{cap}}$ ，可動域の 1 ステップ先読み，トルク変化率の制約下で最小化する（4 変数の逐次二次計画，1 ms 程度）．離手は $\tau_\theta \leq \Delta t/2$ で発火する．すなわち「価値の勾配 $\times$ 既知の力学」から行動が点ごとに導かれ，学習されたのは双対場だけである．比較対象は同じデータからオラクルのトルクを回帰する行動模倣（BC；離手タイマは共通）である．

7.4 密な報酬としての価格

双対場の副産物として，制約種別ごとの価格 $\bar{\Lambda}_k$ （容量乗数で正規化）は強化学習の整形報酬 $r_{\text{dual}} = -\kappa \sum_k \bar{\Lambda}_k \text{viol}_k$ を与える．成功／失敗の疎報酬と異なり，どの物理法則を




図 3 双対場学習の全体像. 上: 状態遷移 (主変数) を学ぶ従来の世界モデルと, 価値・costate・価格 (双対変数) を学ぶ提案の対比. 下: 厳密オラクルの KKT 乗数が双対ラベルを与え, Sobolev 学習した場から既知の力学で行動を導く. 訪問状態はオラクルが再ラベルする.

どれだけ破ったかが, オラクルが与える交換比率で毎ステップ返る.

8. 学習実験

8.1 環境とオラクルの整合

縮約モデルの物理 (拘束振り・自由飛行・順応捕捉, 摩擦錐, 可動域, 壁) を CasADi でコード生成・コンパイルした Gymnasium 環境を用いる (積分 RK4, 1 コアで数千ステップ/秒). 関節可動域は軟らかい生理的ストップ ($15\tau^{\text{cap}}/\text{rad}$), 指令トルクには最適化器と同じ変化率制限, 捕捉は掛かり線が突起先端の 2.5 cm 手前から壁までの箱に許容速度で入ったとき指が反射的に閉じる有限剛性フック (要求力が錐を出ると突起上を滑り, 先端を越えると脱落) としてモデル化した. 指のフックは両崖で, 摩擦・引っ掛かり錐に加えて壁から離れる向きに $0.1F_{\text{cap}}$ の機械的な引っ掛かり容量をもつ. B に掛かった後は身体が B の壁板に触れて突っ張ることを許し (各部位の隙間点と壁板のばね・減衰接触, 100 kN/m, 2 kN s/m; 10 cm を超える食い込みのみ失敗), 振り・飛行中の壁接触 (2 cm 超) は失敗とする. 拘束振りの加速度は最適化器の力学と 10^{-3} の相対精度で一致する. 一方, オラクル軌道を環境で再生できるかどうかは実行系 (制御周期・トルクの標準化・着地反射) に強く依存し, その分解を第 8.4 節で示す. 離手後は方策の役割を終え, 全手法に共通の着地反射 (参照解の飛行関節角プロファイルの PD 追従 + B 先端に対する手先位置の最小二乗補正, 捕捉後は参照解の保持プロファイルの PD 追従) が引き継ぐ. これにより比較の対象を「振りの汲み上げと離手時刻」に限定する.

8.2 双対データとその検証

表 2 に costate の検証を示す. 初期条件パラメータの乗数から得た $\partial J^* / \partial \mathbf{x}_0$ は中心差分と 0.4 % で一致し, 欠陥制約の乗数から復元した軌道上の costate は, 同一問題の初期条件乗数と最大成分の 2.3 % 以内で一致した. したがって 1 本の軌道最適化が N_S 個の状態に双対ラベル (価値, costate, 残り時間, 必要容量) を与える. 現時点で 402 個の残り最適化問題 (うち収束 367) から 33972 個の状態ラベルを得た. 能力パラメータの影の価格 (表 3) は, 関節トルク容量の弾性 $\partial \ln J^* / \partial \ln \tau^{\text{cap}}$ が中央値 -0.27 (平均 -0.59) と最も大きく, 引っ掛かり係数 μ_{out} がこれに次ぎ, 関節角速度上限と捕捉速度の上限は一度も拘束的でない (価格 0) ことを示す. 容量エピソードの乗数は保持相に 85 %, 捕捉衝撃に 14 %, 振りに 2 % が配分され, 必要保持容量を決めているのは振りではなく捕捉後の保持であることが乗数から直接読める.

8.3 双対場の適合と身体間の汎化

双対場ネットワーク (SiLU, 384×3) を, 学習用参照軌道 ($m \neq 69 \text{ kg}$) の 85 % (24810 状態) で学習し, 残る参照軌道 (同じ身体群の未知軌道, 3944 状態) と $m = 69 \text{ kg}$ (未知の身体, 5218 状態) で評価した (表 4). 価値 V と残り時間 τ は未知の身体へ $R^2 = 0.84, 0.97$ で汎化する. costate は活性制約の近傍で桁が跳ぶ重い裾をもつので決定係数は外れ値に支配される; 順位相関 ρ_S と符号一致率で見ると, Sobolev 項があれば未知の身体で $\rho_S = 0.85$, 符号一致 0.87, 未知軌道で 0.73 / 0.82 であるのに対し, 値だけを合わせた場の勾配は $\rho_S = 0.46$, 符号一致 0.65 (未知軌道 0.41 / 0.64) にとどまる. 価値そのものはどちら

表 2 costate の検証 ($T = 18\text{ s}$, $m = 66\text{ kg}$, 振り開始 2.3 s 後の状態).

成分	中心差分	乗数 (初期条件)	乗数 (欠陥制約, 節点外挿)	相対誤差
$\partial J^* / \partial \theta_1$	0.1582	0.1589	0.1625	0.4 % / 2.3 %
$\partial J^* / \partial \dot{\theta}_1$	—	-0.0198	-0.0198	< 0.1 %

表 3 能力パラメータの影の価格 $\partial J^* / \partial \ln p$ (残り最適化問題 367 個の統計) と容量乗数の相別配分.

パラメータ p	$\partial J^* / \partial \ln p$ (中央値)	平均	弾性 $\partial \ln J^* / \partial \ln p$ (中央値)
関節トルク容量 τ^{cap}	-3.902	-10.172	-0.270
引っ掛かり係数 μ_{out}	-0.147	-0.326	-0.010
μ_{in}	-0.020	-0.050	-0.001
関節角速度上限	0.000	0.000	0.000
捕捉相対速度上限	0.000	0.000	0.000
壁から離れる速度上限	0.000	0.000	0.000
容量乗数の配分	保持 85%	捕捉 14%	振り 2%

の学習でも同程度に合うが, その勾配は明示的な双対ラベル無しには学べない. これが「双対を教師にする」ことの直接の根拠である. 行動模倣 (トルク回帰) の未知身体への R^2 は 0.84, 未知軌道では 0.69 であった.

8.4 閉ループ I: 実行系の分解

学習器を比較する前に, オラクル軌道そのものが環境で実行できるかを, 振りは前饋トルク+弱い PD (1/rad, 0.1s/rad), 離手後は共通の着地反射, という実行系で再生して確かめた (表 5). 結果は実行系 (トルクの標本化保持と制御周期) が支配的であることを示す. 制御周期 20 ms で区間始点のトルクを保持する標準的な離散化では, オラクル自身の軌道でさえ 0/6 本しか離手に至らない: 保持による半周期 (10 ms) の位相遅れが, 軽い遠位リンク (前腕・下腿) の速い固有運動を励起して手先力が周期 40–80 ms で振動し, 振り開始 0.2 s 以内に錐を出る (A で滑る). 区間中点でトルクを標本化しても (区分線形トルクに対する零次保持の等価値) 追従誤差は 0.154 rad に達し, 捕捉には至らない. 制御周期を 2 ms (積分 1 ms) にすると 6/6 本が誤差 0.033 rad で離手し, 6/6 本が B を先端から 2–3 cm で捕捉し, 4/6 本が 2 s の保持に成功した (区間始点標本化では 5/6 本; 2 ms では標本点の差は小さい). 保持の失敗はフックの喪失と壁への深い食い込みである: 参照解の保持は壁との隙間制約の上に乗っており, 順応捕捉後の状態は剛体衝突の参照と異なるため, 弱い PD の追従誤差 (0.05–0.15 rad) がそのまま壁への接触になる (保持ゲインを 3–10 倍にしても改善しない). 壁板への突っ張りを接触として許す前は保持成功が 2/6 本であった. 順応捕捉を最適化の内部に置いた参照解 (同じばね・減衰で腕の吸収を計画) でも実行は容易にならない (11/11 離手, 7/11 捕捉, 4/11 保持; 区間始点標本化では 9/11 捕捉, 6/11 保持): その解は膝が可動域端に達する瞬間に離手するため, 離手時刻の 1–2 ms の量子化で膝のストップが働き, 離手直前

に手先力が $1.5 F_{\text{cap}}$ まで跳ね, 飛行が数 cm ずれる. すなわち「最適解の刃」は振りの汲み上げにではなく, 可動域端・壁・錐といったすべての活性制約の上を通る最適解の性質そのものにあり, 閉ループ実行には計画側の制約タイトニング (第 8.5 節) が要る. 以降の閉ループ比較は, 制御周期 2 ms・積分 1 ms・区間中点標本化の実行系に統一する (着地反射の参照は剛体衝突解; オラクル MPC は自身の計画の飛行・保持相を反射に渡す).

8.5 閉ループ II: 双対場からの制御

点ごとの Hamiltonian 最小化 (Pontryagin 制御器) は, 1 制御周期でトルクが価値に与える影響が小さいため H が $\mathbf{u}$ についてほぼ平坦で, costate の 10 % 程度の誤差で最小点が飽和値へ飛ぶ (条件が悪い) ことが分かった. オラクル自身の costate を用いても復元トルクの中央値誤差は 0.07, 最大 0.6 であり, 最適解のトルクは点ごとの最小化では決まらない (変化率制限と離散化のため). そこで, 既知の剛体力学を 0.3 s 先まで陽に積分し, その終端で双対場を評価する短地平線 MPC (計画周期 20 ms, 暗黙 Hermite-Simpson, IPOPT, 価値ネットワークを CasADi に埋め込み厳密微分, 計画は実行周期 2 ms で補間し, 再計画の間は計画の状態軌道を PD 追従) を双対場の制御器とした. 学習した価値場をそのまま終端コストにすると, MPC はデータの外で価値が低く外挿された状態を「発見」してそこへ向かう (0.3 s 先で V_θ が 2–3 低い状態; 学習器と最適化器の敵対). 4 個の場のアンサンブル (平均 +2 σ) だけでは外挿の一致のため防げず, 学習データの混合ガウス密度による分布外ペナルティを終端に加えることで初めて価値の搾取が止まった. 実行側では, オラクル解が引っ掛かり錐と可動域の境界上にあるため, 計画の錐を 25 % + 絶対値 0.03 F_{cap} だけ内側に締め (制約タイトニング), 最初の指令を現在の指令に変化率制限で結び, 与えられた初期状態には制約を課さず, 求解が失敗した周期は

表 4 双対場の適合 (決定係数). val: 学習身体群の未知参照軌道, holdout: 未知の身体 ($m = 69 \text{ kg}$).

モデル	分割	n	$R^2(V)$	$R^2(\tau)$	$\rho_S(\mathbf{p})$	符号一致 ($\mathbf{p}$)	$R^2(\mathbf{u})$
DFL(Sobolev)	train	24810	0.96	0.99	0.89	0.91	0.96
DFL(value-only)	train	24810	0.97	1.00	0.45	0.63	0.96
DFL(Sobolev)	val	3944	0.73	0.95	0.73	0.82	0.69
DFL(value-only)	val	3944	0.71	0.96	0.41	0.64	0.69
DFL(Sobolev)	holdout	5218	0.84	0.97	0.85	0.87	0.84
DFL(value-only)	holdout	5218	0.90	0.99	0.46	0.65	0.84

$T=18 \text{ s}$, $m=66 \text{ kg}$, $\phi_\ell=0.250$: held B ($U_{\text{peak}}=1.56$, $U^*=1.14$)




図 4 シミュレーションのスナップショット ($T = 18 \text{ s}$, $m = 66 \text{ kg}$, $\phi_\ell = 0.25$). 上: オラクル解 (振り・飛行・保持). 下: 同じ解を環境で実行したもの (2ms 実行系+着地反射; B を捕捉して 2s の保持に成功した例). U は保持利用率.

直前の実行可能計画を時間シフトして使う必要があった. 価値場に加えて残り時間場 τ_θ を「地平線ぶん進める」進行項 $w_\tau(\tau_\theta(\mathbf{x}_H, t_H) - (\tau_\theta(\mathbf{x}_0, t_0) - H\Delta t))^2$ を加える変種も評価した (τ は価値勾配より遥かによく汎化するため). 比較のため, 同じ実行系で (i) 行動模倣 (BC), (ii) 双対場 MPC の各変種, (iii) オラクルを 0.5s ごと (および離手の 0.25s 前に最後にもう一度) 解き直し, 自身の計画の飛行・保持相を着地反射に渡すオラクル・イン・ザ・ループ MPC (計算量の上限; 1 エピソード 5–25 分) を評価した (表 6). 行動模倣は 10 エピソード中, 離手 0, 捕捉 0, 保持成功 0, 双対場 MPC (全変種の合計) は 49 エピソード中, 離手 1, 捕捉 0, 保持成功 0, オラクル MPC (再計画変種の合計) は 10 エピソード中, 離手 10, 捕捉 4, 保持成功 1 であった. オラクル・イン・ザ・ループ MPC は, 振りの途中で摂動を受けても 10 本すべてで離手に到達し, 自身の計画を渡された着地反射が 4 本で B 先端を 2.4–3.0cm で捕らえ (もう 1 本は先端を 4mm で通過したが接近速度の条件を満たさず), 1 本が 2s の保持に成功した (残りはフックの喪失). 外れた 4 本は離手前 0.5s の PD 追従で生じた状態のずれが飛行で 0.2m に増幅されたもので, 離手の 0.25s 前にもう一度解き直す試みは, タイミングした制約の下では多くの場合実現可能解を持たない (ずれた状態からは捕捉が到達不能). 双対場 MPC は, 価値終端のみ・地平線延長・ τ 進行項・初期節点の制約緩

和・計画の PD 追従のどの変種でも, 振りの途中で錐が出る, 壁に触れる, 容量を超えるのいずれかで失敗し, 離手に至ったのは 49 本中 1 本 (それも B から 2m 離れた離手) であった. 計画を PD 追従する変種は期限の 18s まで生存する試行が 3 本あるが, 離手条件 $\tau_\theta \leq \Delta t/2$ には達しない. その理由は場の精度と地平線の関係から見積もれる: 価値 V の未知軌道・未知身体での RMSE は $1.06 / 0.83$ (V の標準偏差 2.05) であるのに対し, 最適軌道に沿って価値が 0.3s の地平線内で変化する量は 0.28 (0.8s でも 0.74) にすぎない. 終端価値が地平線先の候補状態を順位付けできる条件は $\text{RMSE} \ll \text{地平線内の価値変化}$ であり, 現在の場合はこの条件を 3 倍以上下回る. 残り時間場 τ (RMSE 0.35 / 0.24s) の進行項は振りの汲み上げ自体は起こす (τ_θ が実時間の 1.4 倍の速さで減る) が, 汲み上げが活性制約 (錐・容量) の内側に留まるかは価値勾配の精度に依り, そこで失敗する. すなわち, 双対場は表現としては検証できた (値・残り時間・価格の汎化, 勾配の順位) が, この課題の制御器として働くには価値の精度をあと一桁上げる必要があり, それには訪問状態のオラクル再ラベル (DAgger) と, 可動域端・壁・錐に余裕をもつロバスト・オラクルが要る (第 10 節).

8.6 強化学習との比較

同じ環境・同じ着地反射で PPO (8 並列環境, 300 万ス

表 5 実行系の分解：オラクル軌道の環境再生 ($T = 18\text{ s}$, $m \in \{60, \dots, 75\} \text{ kg}$; 剛体衝突解は $\phi_\ell = 0.25$, 順応捕捉解は $\phi_\ell \in \{0.25, 0.31\}$). 離手・捕捉・保持 (2 s) に至った本数と振り中の関節角追従誤差の中央値.

制御周期	前饋トルクの標本点	参照解の捕捉モデル	n	離手	捕捉	保持 (2 s)	振り追従誤差の中央値 [rad]
2 ms	区間中点	順応	11	11	7	4	0.029
2 ms	区間中点	剛体衝突	6	6	6	4	0.033
2 ms	区間始点	順応	11	11	9	6	0.029
2 ms	区間始点	剛体衝突	6	6	6	5	0.033
20 ms	区間中点	順応	11	2	0	0	0.125
20 ms	区間中点	剛体衝突	6	0	0	0	0.141
20 ms	区間始点	順応	11	0	0	0	0.116
20 ms	区間始点	剛体衝突	6	0	0	0	0.154

表 6 閉ループ評価 ($T = 18\text{ s}$, $m \in \{60, 63, 66, 69, 72\} \text{ kg}$ の参照解, 静止開始+摂動開始 (振り途中の状態に角度 0.03 rad ・角速度 0.2 rad/s の雑音); $m = 69 \text{ kg}$ は学習に用いない身体; 実行系は 2 ms ・区間中点標本化・共通の着地反射). 離手・捕捉・保持 (2 s, 成功) に至った割合, 離手した試行の手先と B 先端の最接近距離の中央値, 失敗までの生存時間.

制御器	n	離手	捕捉	保持 (成功)	最接近中央値 [cm]	生存時間中央値 [s]	U_{peak} 中央値	主な失敗
行動模倣 (BC)	10	0%	0%	0%	—	2.7	0.84 ($U^*=1.14$)	A で滑り
双対場 MPC (V 終端, 0.3 s)	10	0%	0%	0%	—	2.3	1.15 ($U^*=1.14$)	壁に接触
双対場 MPC (V 終端, 0.8 s)	10	10%	0%	0%	232.9	2.7	1.23 ($U^*=1.14$)	A で滑り
双対場 MPC (V + τ 進行, 0.3 s)	10	0%	0%	0%	—	2.8	1.35 ($U^*=1.14$)	壁に接触
双対場 MPC (V + τ 進行, 初期制約緩和)	10	0%	0%	0%	—	9.0	1.55 ($U^*=1.14$)	壁に接触
双対場 MPC (V + τ 進行, 計画の PD 追従)	9	0%	0%	0%	—	5.4	1.19 ($U^*=1.14$)	A で滑り
オラクル MPC	10	100%	40%	10%	3.8	5.7	1.36 ($U^*=1.14$)	B 前面に衝突

テップ) を, 疎報酬, 振りエネルギー整形, 最接近距離整形, 双対価格整形の組合せについて学習させた (図 5). 初期の報酬設計では「早く死ぬ」「即離手」「期限まで静止」の三つの局所解が順に現れ, 早期失敗ペナルティ・指令変化率制限・離手閾値の導入後は全条件が「期限まで静止」(報酬 $-109 \sim -121$) に収束し, 300 万ステップで成功は一度も観測されなかった (0 回/75688 エピソード). 参照状態初期化 (DeepMimic 型, オラクル軌道上の状態から 70% のエピソードを開始) を加えると離手は生じる (エネルギー整形で 5 割) が, 最接近距離は 1.3 m 以上で捕捉には至らない. (強化学習の実行は閉ループ評価より前の環境版で行い, A 側の滑り判定に指のフック容量項を含まない; この項は滑りを緩める方向にしか働かない.) 本課題では疎な成功信号に基づく方策探索は, 密な双対情報 (価値・costate・価格) を持つオラクル駆動の学習よりはるかに非効率であることが, 同一環境で確認された.

9. ロボティクスへの含意

本研究の対象は人体だが, 方法論はそのままロボットに移る. 第一に, **必要容量マップ** は設計仕様である. 3 cm 縁を両手で捕捉する動作に要る把持力 (体重比 2.3–2.7 BW), 関節トルクの弾性 ($\partial \ln J^* / \partial \ln \tau^{\text{cap}} \approx -0.27$), 離手位相の実行可能窓 ($\phi_\ell \in [0.25, 0.31]$) は, 腕渡り・懸垂移動ロボットのアクチュエータとグリップの要求仕様をそのまま与

える. 第二に, **双対場** は「どの制約がいつ効くか」を場として保持するので, 同じ物理の異なる個体 (質量・リンク長・アクチュエータ容量) への転移が包絡線定理で一次近似でき, 新個体ごとの再学習を減らす. ロボットでは剛体力学が既知なので, 双対場 MPC は方策学習なしに直接使える. 第三に, **価格を報酬にする** 整形は, 安全制約 (把持容量・摩擦錐・可動域) のペナルティ重みを人手ではなくオラクルの交換比率で決める方法であり, 制約付き強化学習のラグランジュ乗数を物理オラクルから初期化・固定する使い方に相当する. 第四に, 環境と最適化器が同一の記号力学を共有する設計 (コード生成した縮約物理) は, 学習器を厳密な最適解と同じ土俵で測るための実験基盤として一般に有用である.

10. 限界と今後

平面縮約モデルは矢状面のみを扱い, 3 次元ひねりモデルによる片手ずつの捕捉負荷の掃引は計算中である. 把持容量は両手合算の絶対値で, 指の疲労・皮膚摩擦の個人差を含まない. 双対場学習は現段階で小規模 (367 個の残り最適化, 33972 状態) であり, 閉ループの成否はデータ量よりもまず実行系に支配された (第 8.4 節): 最適解は可動域端・壁・錐のすべてに触れるので, 計画側に余裕 (制約タイトニング) のない参照は数 ms の離散化誤差で崩れる. 余裕を目的関数に含めるロバスト定式化 (離手時刻誤差の




図5 PPOの学習曲線（移動平均，破線は参照状態初期化）：離手したエピソードの手先とB先端の最接近距離，エピソード長，離手率．最接近距離はどの条件でも1.3mを下回らず（オラクル解では2cm以内），学習は「期限まで静止」へ収束する．

シナリオは実装済み）を双対場のオラクルにすることが，閉ループ成功率を上げる最短の道である．costateの学習は価値の学習より本質的に難しく（未知身体で $R^2 \approx 0.39$ ），点ごとのPontryagin制御は条件が悪い．短地平線の厳密力学と組み合わせるMPCが必要であった．今後は，(i) 3次元モデルの双対場，(ii) KKT系の2次感度（Riccati型の価値ヘッセ行列）を用いた軌道近傍の2次双対ラベル，(iii) 実行時に余裕を持つロバスト最適解（離手時刻誤差・順応捕捉のシナリオ）の双対場，(iv) MuJoCo環境への転移を進める．

11. まとめ

クリフディメンションの背面飛び移りを，装置運動・3cm突起・有限把持容量・前腕干渉を含む力学課題として定式化し，決定論的な軌道最適化により離手位相の実行可能窓と必要把持容量を求め，乗数によって支配制約（捕捉後の保持）と能力弾性（関節トルク）を同定した．さらに，その双対変数を学習の対象とする双対場学習を提案し，costateラベルの厳密性，未知身体への汎化，Pontryagin制御の条件の悪さと短地平線MPCによる解決，強化学習の疎報酬下での停滞を同一環境で示した．閉ループでは，最適解がすべての活性制約の上を通るため実行系の離散化（20ms零次保持）だけでオラクル軌道が崩れること，2msの実行系と着地反射で参照解の捕捉・保持が再現されること，学習した双対場MPCが同じ実行系でオラクル・イン・ザ・ループMPCとどこまで並ぶかを定量化した．コードと結果は<https://github.com/omotes24/CliffDimension>にある．

参考文献

- [1] J. E. A. Bertram, A. Ruina, C. E. Cannon, Y. H. Chang, and M. J. Coleman, “A point-mass model of gibbon locomotion,” *J. Exp. Biol.*, vol. 202, pp. 2609–2617, 1999.
- [2] J. R. Usherwood and J. E. A. Bertram, “Understanding brachiation: insight from a collisional perspective,” *J. Exp. Biol.*, vol. 206, pp. 1631–1642, 2003.
- [3] M. W. Gomes and A. L. Ruina, “A five-link 2D brachiating ape model with life-like zero-energy-cost motions,” *J. Theor. Biol.*, vol. 237, pp. 265–278, 2005.
- [4] F. Saito, T. Fukuda, and F. Arai, “Swing and locomotion control for a two-link brachiation robot,” *IEEE Control Syst. Mag.*, vol. 14, no. 1, pp. 5–12, 1994.
- [5] J. Nakanishi, T. Fukuda, and D. E. Koditschek, “A brachiating robot controller,” *IEEE Trans. Robot. Autom.*, vol. 16, no. 2, pp. 109–123, 2000.
- [6] D. Reda, H. Y. Ling, and M. van de Panne, “Learning to brachiate via simplified model imitation,” *Proc. ACM SIGGRAPH*, 2022.
- [7] T. R. Kane and M. P. Scher, “A dynamical explanation of the falling cat phenomenon,” *Int. J. Solids Struct.*, vol. 5, pp. 663–670, 1969.
- [8] C. Frohlich, “Do springboard divers violate angular momentum conservation?” *Am. J. Phys.*, vol. 47, pp. 583–592, 1979.
- [9] M. R. Yeadon, “The biomechanics of twisting somersaults. Part I: Rigid body motions,” *J. Sports Sci.*, vol. 11, pp. 187–198, 1993.
- [10] C. R. Hargraves and S. W. Paris, “Direct trajectory optimization using nonlinear programming and collocation,” *J. Guid. Control Dyn.*, vol. 10, pp. 338–342, 1987.
- [11] J. T. Betts, *Practical Methods for Optimal Control and Estimation Using Nonlinear Programming*, 2nd ed., SIAM, 2010.
- [12] M. Kelly, “An introduction to trajectory optimization: How to do your own direct collocation,” *SIAM Rev.*, vol. 59, no. 4, pp. 849–904, 2017.
- [13] M. Posa, C. Cantu, and R. Tedrake, “A direct method for trajectory optimization of rigid bodies through contact,” *Int. J. Robot. Res.*, vol. 33, no. 1, pp. 69–81, 2014.
- [14] I. Mordatch, E. Todorov, and Z. Popović, “Discovery of complex behaviors through contact-invariant optimization,” *ACM Trans. Graph.*, vol. 31, no. 4, 2012.
- [15] A. V. Fiacco, “Sensitivity analysis for nonlinear programming using penalty methods,” *Math. Program.*, vol. 10, pp. 287–311, 1976.
- [16] C. Büskens and H. Maurer, “Sensitivity analysis and real-time optimization of parametric nonlinear programming problems,” in *Online Optimization of Large Scale Systems*, Springer, pp. 3–16, 2001.
- [17] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft actor-critic,” *Proc. ICML*, 2018.
- [18] X. B. Peng, P. Abbeel, S. Levine, and M. van de Panne, “DeepMimic: Example-guided deep reinforcement learning for brachiation,” *Proc. ICML*, 2018.

- ment learning of physics-based character skills,” *ACM Trans. Graph.*, vol. 37, no. 4, 2018.
- [19] D. Ha and J. Schmidhuber, “World models,” *arXiv:1803.10122*, 2018.
 - [20] D. Hafner, T. Lillicrap, J. Ba, and M. Norouzi, “Dream to control: Learning behaviors by latent imagination,” *Proc. ICLR*, 2020.
 - [21] D. Hafner, J. Pasukonis, J. Ba, and T. Lillicrap, “Mastering diverse control tasks through world models,” *Nature*, vol. 640, pp. 647–653, 2025.
 - [22] N. Hansen, X. Wang, and H. Su, “Temporal difference learning for model predictive control,” *Proc. ICML*, 2022.
 - [23] S. Levine and V. Koltun, “Guided policy search,” *Proc. ICML*, 2013.
 - [24] S. Ross, G. J. Gordon, and J. A. Bagnell, “A reduction of imitation learning and structured prediction to no-regret online learning,” *Proc. AISTATS*, 2011.
 - [25] K. Lowrey, A. Rajeswaran, S. Kakade, E. Todorov, and I. Mordatch, “Plan online, learn offline: Efficient learning and exploration via model-based control,” *Proc. ICLR*, 2019.
 - [26] M. Fairbank and E. Alonso, “Value-gradient learning,” *Proc. IJCNN*, 2012.
 - [27] W. M. Czarnecki, S. Osindero, M. Jaderberg, G. Świrszcz, and R. Pascanu, “Sobolev training for neural networks,” *Proc. NeurIPS*, 2017.
 - [28] N. Heess, G. Wayne, D. Silver, T. Lillicrap, T. Erez, and Y. Tassa, “Learning continuous control policies by stochastic value gradients,” *Proc. NeurIPS*, 2015.
 - [29] W. Jin, Z. Wang, Z. Yang, and S. Mou, “Pontryagin differentiable programming: An end-to-end learning and control framework,” *Proc. NeurIPS*, 2020.
 - [30] S. Bansal and C. J. Tomlin, “DeepReach: A deep learning approach to high-dimensional reachability,” *Proc. ICRA*, 2021.
 - [31] J. Achiam, D. Held, A. Tamar, and P. Abbeel, “Constrained policy optimization,” *Proc. ICML*, 2017.
 - [32] C. Tessler, D. J. Mankowitz, and S. Mannor, “Reward constrained policy optimization,” *Proc. ICLR*, 2019.
 - [33] P. B. Watts, “Physiology of difficult rock climbing,” *Eur. J. Appl. Physiol.*, vol. 91, pp. 361–372, 2004.
 - [34] A. M. Amca, L. Vigouroux, S. Aritan, and E. Berton, “Effect of hold depth and grip technique on maximal finger forces in rock climbing,” *J. Sports Sci.*, vol. 30, no. 7, pp. 669–677, 2012.
 - [35] P. de Leva, “Adjustments to Zatsiorsky-Seluyanov’s segment inertia parameters,” *J. Biomech.*, vol. 29, no. 9, pp. 1223–1230, 1996.
 - [36] A. Wächter and L. T. Biegler, “On the implementation of an interior-point filter line-search algorithm for large-scale nonlinear programming,” *Math. Program.*, vol. 106, pp. 25–57, 2006.
 - [37] J. A. E. Andersson et al., “CasADi: a software framework for nonlinear optimization and optimal control,” *Math. Program. Comput.*, vol. 11, pp. 1–36, 2019.
 - [38] E. Todorov, T. Erez, and Y. Tassa, “MuJoCo: A physics engine for model-based control,” *Proc. IROS*, 2012.